面向异步多模态电子医疗档案的时间感知医疗大模型

一、立项依据

1. 项目的研究意义及科学依据

大模型正在推动医疗人工智能从面向单一数据模态、单一任务的专用建模，转向对多源医学信息的统一表征、跨模态理解和多任务迁移，为构建可适配不同临床场景的通用医疗人工智能提供了新的路径 [5,10]。电子医疗档案（electronic health record, EHR）是承载患者纵向、多模态信息的核心载体，为这一转变提供了重要的数据基础；但其数据形态与当前医疗多模态大模型主要依赖的图文对、单次检查或近似同步样本存在根本差异。床旁监护、实验室检验、医学影像和临床文本由不同机制触发，以不同频率和时间粒度记录，在任一临床决策时刻呈现不同的可用性与时效性 [1-3,6,11]。这种数据形态上的差异，使现有医疗多模态大模型在处理异步 EHR 数据时集中暴露出三类方法瓶颈：一是时序模态的表示难以同时容纳复杂采样模式并参与跨模态建模；二是数据缺失或因时间间隔而失效的模态缺少面向目标时刻的可靠生成与融合机制；三是时间信息的输入没有自然转化为依据真实时间关系组织多模态证据的时间感知能力。

第一，临床时序的表示学习，其研究基础与视觉、语言模态并不对称。视觉和语言已有相对成熟的预训练编码与基座模型适配路径；相比之下，临床时序同时包含规则与不规则采样、单变量与多变量、高频连续波形与低频离散事件，其采样时间、采样密度和缺失模式还可能反映患者状态及诊疗过程。现有通用或医疗时序基础模型（time series foundation model, TSFM）多围绕时序预测和分类建立，面对临床多变量、通道非同步的数据时，往往需要在变量关系、采样模式和多尺度动态之间权衡。将其接入多模态基座模型时，整段序列压缩、保留细粒度词元（token）和固定时间栅格重采样又分别面临局部信息弱化、上下文开销增加和采样模式被抹平的问题，难以形成兼顾临床时序特征与目标时刻跨模态关联的表示 [14-22,30,31,36,39,50-52]。第二，临床模态缺失不仅指某类数据从未采集，也包括最近一次观测虽存在、却因病程变化和时间间隔增长而不足以代表当前状态的情况。现有插补、缺失鲁棒融合和表示生成方法大多针对特定数据组合与下游任务设计，没有统一考虑目标时刻潜在模态状态的生成、生成表示与真实证据的协同使用，以及生成结果的可靠性控制。生成的嵌入（embedding）接入基座模型并迁移

到不同任务时，这一局限会更加突出 [7-9,27-29,37,40]。第三，时间戳文本化、按时间排序 token 或附加时间与位置编码，主要解决时间信息如何被输入，却不能保证基座模型理解时间坐标与多模态内容之间的对应关系。EHR 数据同时包含点观测和连续片段，真正的时间感知还要求模型以真实物理时间为参照，理解跨模态证据的先后、间隔、持续与时效，据此改变对证据的选择、关联和使用。因此，现有时间接入方法与这种可用于多模态推理的内在能力之间仍有明显距离 [4,22,25,26,45,50]。

上述瓶颈制约的并非若干单项任务的性能，而是医疗大模型能否从静态、局部的信息处理走向对患者纵向过程的整体理解。异步采集、信息性缺失和证据时效共同决定了临床证据在目标时刻是否可用；因此，这些因素若不能被纳入统一的多模态建模框架，持续积累的临床数据就难以转化为可复用、可迁移的患者状态表征，医疗人工智能也难以进一步支持跨场景的病程理解和动态决策 [5,6,11]。基于这一认识，本项目面向异步 EHR 数据，依托现有视觉、语言及时序预训练模型，系统研究面向多模态建模的临床时序表征，缺失模态的生成式补全、可靠性评估及融合，以及多模态大模型对异步多模态数据的时间感知。在此基础上，项目将通过参数高效微调（parameter-efficient fine-tuning, PEFT）开展多模态后训练（multimodal post-training），使三类能力在已有基座模型中协同形成，并在不同临床任务、模态可用条件和时间关系变化下检验其迁移性、可靠性及时间感知能力。由此，项目有望推动医疗大模型从以图文对和同步样本为主的建模范式，拓展到以患者为中心的连续、异步和不完整临床过程建模，提高其对真实临床数据形态和不同应用场景的适应能力。项目形成的方法、模型和评测工具还将促进纵向多模态 EHR 数据的有效利用，降低临床智能应用对同步完整数据和任务专用模型的依赖，为病程演变分析、动态风险评估和临床决策支持提供可复用的技术基础，并为后续与医疗机构开展真实临床流程中的合作验证创造条件。

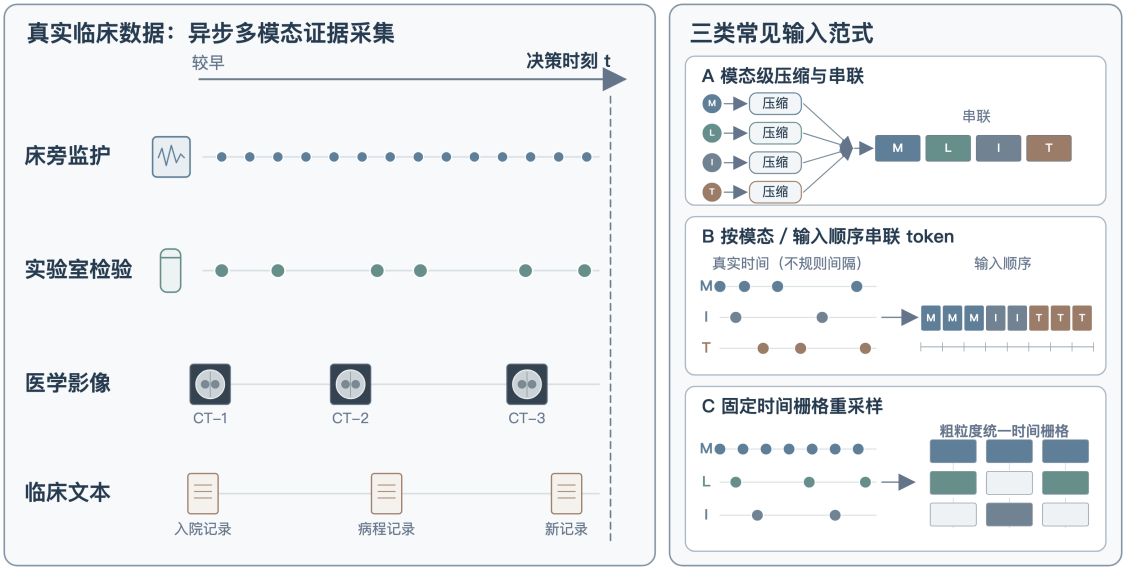


图 1　异步临床多模态证据采集与三类常见输入范式。左侧展示床旁监护、实验室检验、医学影像和临床文本沿真实时间轴异步到达；右侧对比模态级压缩与串联、按模态 / 输入顺序串联 token 以及固定时间栅格重采样三种常见输入方式，说明其对真实时间关系和采样结构的不同处理。

2. 国内外研究现状分析

2.1 时序数据及其基础模型

临床时序既包含规则采样的高频波形，也包含不规则、多变量且通道非同步的检验与事件。针对这些不同形态，通用时序模型已发展出分块、频域或时频变换、离散量化和多尺度建模等路线；在此基础上，Chronos、TimesFM 等 TSFM 通过大规模预训练获得零样本或少样本迁移能力 [14-17]，MIRA 等医疗 TSFM 也开始处理连续时间、异质采样率和任意目标时刻预测 [36]。多数 TSFM 仍以单变量或通道独立方式预训练，多变量适配还需要额外学习变量交互 [51]。即使部分通用模型能够容纳可变数量的变量 [52]，其目标也主要是时序内部预测；相比之下，临床数据的观测时间、采样频率和缺失状态本身还会受到患者状态与诊疗行为影响 [30,31,39]。TSFM 输出接入基座模型时，整段压缩会弱化局部动态和目标时刻关系，保留全部 token 会造成上下文负担，固定重采样又可能抹去采样模式。为此还需研究整段表示、分段 token 与条件化多尺度重采样在变量关系、跨模态匹配和 token 预算之间的适用边界 [20-22,44,50]。

2.2 多模态 EHR 及模态缺失的研究

多模态 EHR 研究已从时序、影像和文本的特征拼接，逐步发展到潜在跨模态对应学习、共享—特有表示分解、缺失鲁棒融合及联合嵌入空间中的表示预测

[4,7,8,37,45]；生成模型也已用于不完整时序的概率插补 [27-29]。多数方法仍把模态状态简化为“存在或缺失”，较少区分从未采集、由观测机制导致的未采集，以及最近观测因间隔过长而失效。针对异步采集造成的时效衰减，团队前期研究表明，利用历史影像和区间 EHR 生成目标时刻的影像 embedding，并将其与真实证据融合，可以改善目标时刻的信息覆盖 [9]。纵向建模还显示，影像表示同时包含相对稳定与动态变化的信息，影像和 EHR 在局部区间与完整病程两个尺度上均存在对应关系 [40]。这些进展为表示空间补全提供了基础；但由于现有生成关系多绑定于特定任务，接入基座模型后仍需解决可靠性控制、真实—生成证据平衡和跨任务迁移等问题。

2.3 多模态大模型的时间感知

现有多模态大模型的时间接入方法主要包括将时间戳或数值序列转写为文本、按输入顺序串联多模态 token，以及附加时间或位置编码。不规则时序模型还使用时间间隔、衰减函数和连续时间注意力处理采样不齐，视频多模态模型则通过时间任务学习事件先后、区间和时段 [18-22,25,26,50]。这些研究共同说明，时间信息只有参与内容组织和任务学习，才可能转化为模型可以运用的能力。临床 EHR 同时包含影像检查时点、连续波形片段、文本叙述区间和稀疏结构化事件，仅靠文本化、token 次序或单点位置编码，仍要求基座模型从压缩输入中重新恢复各表示对应的真实时点、持续区间及跨模态关系，容易形成信息瓶颈，或者把物理时间混同于输入顺序 [4,45]。需要研究的核心不是继续增加一种时间编码，而是如何依据真实时点或区间组织异步多模态 embedding，并检验模型的证据选择和推理是否真正随先后、间隔、持续和时效关系改变。

2.4 现有研究的不足与本项目的切入点

承接上述三个研究方向，现有方法的不足主要体现在三个相互关联的方面。其一，现有 TSFM 的预训练先验主要服务于时序内部的预测或分类，在临床多变量和通道非同步场景中，仍需进一步处理变量关系与采样模式。整段压缩、保留全部 token 或固定重采样又分别带来局部动态弱化、上下文开销增加和采样信息损失，限制时序表示在目标时刻建立跨模态关联的能力。其二，缺失模态的生成式补全多由特定任务监督，现有方法通常将生成表示的可靠性评估和后续融合分别处理，生成关系也容易绑定于训练任务。因此，生成表示与真实证据难以协同使用，跨任务

迁移能力也受到限制。其三，时间戳文本化、token 排序或附加时间编码仅将时间作为附加信息输入，跨模态物理时间关系仍依赖基座模型从压缩输入中自行恢复，模型缺乏对异步多模态数据真正的时间感知。

基于上述不足，本项目采用 PEFT，在充分复用已有开源多模态基座模型的视觉—语言知识、跨模态交互和指令跟随能力的基础上，重点解决三个方面的问题[12,32,33]。针对临床时序表征，项目将在整段、分段和面向目标时刻的多尺度重采样等多种方法的基础上，研究如何在有限 token 预算下保留数值动态、变量关系、医学概念语义、真实观测时间和采样状态，并使时序表示能够与影像、文本等模态建立目标时刻关联。针对模态缺失与证据失效，项目将利用历史真实观测、当前可用模态、观测状态和时间间隔，生成缺失模态在目标时刻的候选 embedding，结合来源、不确定性、内容—时间一致性及下游效用开展可靠性评估，并研究生成表示与真实证据的融合。针对时间感知，项目将依据真实时点或区间组织异步多模态 embedding，通过跨模态聚合和自适应时间分辨率形成数量可控的多模态时间表示，并通过针对性后训练，使模型的证据选择和推理真正随先后、间隔、持续和时效关系改变。上述三项能力并非彼此独立，项目将通过统一的 PEFT 过程使其协同接入基座模型，并采用分阶段训练、模块分层更新、模态与任务目标平衡以及后训练前后能力对照，研究和控制文本主导、模态学习失衡、token 预算竞争、组件更新不平衡及原有能力下降等 PEFT 问题 [47-49]。项目还将在不同临床任务、模态可用条件、时间跨度和基座模型上检验三项能力的迁移性、可靠性及适用边界，推动医疗大模型从同步、静态样本处理拓展到连续、异步且不完整的患者过程建模，提高纵向多模态 EHR 的利用效率，并为病程理解、动态风险评估和临床决策支持提供可复用的方法与技术基础。完整研究目标、关键科学问题和实施方案在第二部分集中展开。

3. 主要参考文献及出处

[1] Johnson AEW, Bulgarelli L, Shen L, et al. MIMIC-IV, a freely accessible electronic health record dataset. Scientific Data. 2023. 10(1): 1.

[2] Johnson AEW, Pollard TJ, Berkowitz SJ, et al. MIMIC-CXR, a de-identified publicly available database of chest radiographs with free-text reports. Scientific Data. 2019. 6(1): 317.

[3] Harutyunyan H, Khachatrian H, Kale DC, et al. Multitask learning and benchmarking with clinical time series data. Scientific Data. 2019. 6(1): 96.

[4] Yu K, Yang R, Liao J, et al. Benchmarking foundation models with multimodal public electronic health records. IEEE Journal of Biomedical and Health Informatics. 2025. DOI: 10.1109/JBHI.2025.3645076.

[5] Moor M, Banerjee O, Abad ZSH, et al. Foundation models for generalist medical artificial intelligence. Nature. 2023. 616(7956): 259-265.

[6] Wornow M, Xu Y, Thapa R, et al. The shaky foundations of large language models and foundation models for electronic health records. npj Digital Medicine. 2023. 6: 135.

[7] Hayat N, Geras KJ, Shamout FE. MedFuse: Multi-modal fusion with clinical time-series data and chest X-ray images. Machine Learning for Healthcare. 2022.

[8] Yao W, Yin K, Cheung WK, Liu J, Qin J. DrFuse: Learning disentangled representation for clinical multi-modal fusion with missing modality and modal inconsistency. AAAI. 2024. 38(15): 16416-16424.

[9] Yao W, Liu C, Yin K, Cheung WK, Qin J. Addressing asynchronicity in clinical multimodal fusion via individualized chest X-ray generation. NeurIPS. 2024: 29001-29028.

[10] Tu T, Azizi S, Driess D, et al. Towards generalist biomedical AI. NEJM AI. 2024. 1(3).

[11] Schouten D, Nicoletti G, Dille B, et al. Navigating the landscape of multimodal AI in medicine: A scoping review on technical challenges and clinical applications. Medical Image Analysis. 2025. 105: 103621.

[12] Li C, Wong C, Zhang S, et al. LLaVA-Med: Training a large language-and-vision assistant for biomedicine in one day. NeurIPS. 2023.

[13] Moor M, Huang Q, Wu S, et al. Med-Flamingo: A multimodal medical few-shot learner. Proceedings of Machine Learning Research. 2023. 225: 353-367.

[14] Ansari AF, Stella L, Turkmen C, et al. Chronos: Learning the language of time series. Transactions on Machine Learning Research. 2024.

[15] Das A, Kong W, Sen R, Zhou Y. A decoder-only foundation model for time-series forecasting. ICML. 2024.

[16] Nie Y, Nguyen NH, Sinthong P, Kalagnanam J. A time series is worth 64 words: Long-term forecasting with transformers. ICLR. 2023.

[17] Liu Y, Hu T, Zhang H, et al. iTransformer: Inverted transformers are effective for time series forecasting. ICLR. 2024.

[18] Shukla SN, Marlin BM. Multi-time attention networks for irregularly sampled time series. ICLR. 2021.

[19] Zhang X, Li S, Chen Z, et al. Graph-guided network for irregularly sampled multivariate time series. ICLR. 2022.

[20] Zhang J, Zheng S, Cao W, et al. Warpformer: A multi-scale modeling approach for irregular clinical time series. KDD. 2023.

[21] Xiao T, Xu Z, He W, et al. XTSFormer: Cross-temporal-scale transformer for irregular-time event prediction in clinical applications. AAAI. 2025. 39(27): 28502-28510.

[22] Zhang W, Yin C, Liu H, Xiong H. Unleashing the power of pre-trained language models for irregularly sampled time series. KDD. 2025: 3831-3842.

[23] Zhong S, Zhuo W, Song S, et al. MTM: A multi-scale token mixing transformer for irregular multivariate time series classification. KDD. 2025: 4074-4085.

[24] Zhong S, Song S, Li G, et al. A multi-scale decomposition MLP-mixer for time series analysis. Proceedings of the VLDB Endowment. 2024. 17(7): 1723-1736.

[25] Ren S, Yao L, Li S, et al. TimeChat: A time-sensitive multimodal large language model for long video understanding. CVPR. 2024: 14313-14323.

[26] Geng T, Zhang J, Wang Q, et al. LongVALE: Vision-audio-language-event benchmark towards time-aware omni-modal perception of long videos. CVPR. 2025: 18959-18969.

[27] Tashiro Y, Song J, Song Y, Ermon S. CSDI: Conditional score-based diffusion models for probabilistic time series imputation. NeurIPS. 2021.

[28] Alcaraz JML, Strodthoff N. Diffusion-based time series imputation and forecasting with structured state space models. Transactions on Machine Learning Research. 2022.

[29] Dai Z, Getzen E, Long Q. SADI: Similarity-aware diffusion model-based imputation for incomplete temporal EHR data. Proceedings of Machine Learning Research. 2024.

[30] Groenwold RHH. Informative missingness in electronic health record systems: the curse of knowing. Diagnostic and Prognostic Research. 2020. 4: 8.

[31] Tan ALM, Getzen E, Hutch MR, et al. Informative missingness: What can we learn from patterns in missing laboratory data in the electronic health record? Journal of Biomedical Informatics. 2023. 139: 104306.

[32] Hu EJ, Shen Y, Wallis P, et al. LoRA: Low-rank adaptation of large language models. ICLR. 2022.

[33] Liu H, Li C, Li Y, Lee YJ. Improved baselines with visual instruction tuning. CVPR. 2024: 26286-26296.

[34] Liang VW, Zhang Y, Kwon Y, Yeung S, Zou J. Mind the gap: Understanding the modality gap in multi-modal contrastive representation learning. NeurIPS. 2022: 17612-17625.

[35] Wang W, Tran D, Feiszli M. What makes training multi-modal classification networks hard? CVPR. 2020: 12692-12702.

[36] Li H, Deng B, Xu C, et al. MIRA: Medical time series foundation model for real-world health data. Advances in Neural Information Processing Systems. 2025. 38.

[37] Kim D, Kim T. Missing modality prediction for unpaired multimodal learning via joint embedding of unimodal models. European Conference on Computer Vision. 2024: 171-187.

[38] Zhong S. Multivariate Time Series Analysis with Deep Learning. Doctoral thesis, The Hong Kong University of Science and Technology. 2026. DOI: 10.14711/thesis-hdl171509.

[39] Yin K, Qian D, Cheung WK. PATNet: Propensity-adjusted temporal network for joint imputation and prediction using binary EHRs with observation bias. IEEE Transactions on Knowledge and Data Engineering. 2024. 36(6): 2600-2613.

[40] Liu C, Yao W, Yin K, Cheung WK, Qin J. Multimodal disease progression modeling via spatiotemporal disentanglement and multiscale alignment. NeurIPS. 2025.

[41] Chen Z, Yin K, Yao W, Cheung WK, Qin J. MASAM: Multimodal adaptive sharpness-aware minimization for heterogeneous data fusion. ICLR. 2026.

[42] Wang Z, Yan S, Yin K, Zhang X, Cheung WK. CURV: Coherent uncertainty-aware reasoning in vision-language models for X-ray report generation. NeurIPS. 2025.

[43] Yan S, Wang Z, Yin K, Cheung WK, Cheung KC, See S. Learning self-critiquing mechanisms for region-guided chest X-ray report generation. ICLR. 2026.

[44] Cheong CW, Yin K, Cheung WK, Fung BCM, Poon J. Adaptive integration of categorical and multi-relational ontologies with EHR data for medical concept embedding. ACM Transactions on Intelligent Systems and Technology. 2023. 14(6): 111.

[45] Yin K, Cheung WK, Fung BCM, Poon J. Learning inter-modal correspondence and phenotypes from multi-modal electronic health records. IEEE Transactions on Knowledge and Data Engineering. 2022. 34(9): 4328-4341.

[46] Yin K, Xu H, Yao W, et al. When does multimodal learning help in healthcare? A benchmark on EHR and chest X-ray fusion. arXiv:2602.23614. 2026.

[47] Bi J, Wang Y, Chen H, et al. LLaVA Steering: Visual instruction tuning with 500x fewer parameters through modality linear representation-steering. ACL. 2025: 15230-15250.

[48] Li X, Wu J, Yu T, et al. CoMMIT: Coordinated multimodal instruction tuning. EMNLP. 2025: 11522-11536.

[49] Huang W, Liang J, Shi Z, et al. Learn from downstream and be yourself in multimodal large language models fine-tuning. ICML. 2025: 25486-25499.
[50] Ye J, Zhang W, Li Z, Li J, Zhao M, Tsung F. MedualTime: A dual-adapter language model for medical time series-text multimodal learning. IJCAI. 2025: 7913-7921.
[51] Liu M, Chen AH, Chen GH. Generalized prompt tuning: Adapting frozen univariate time series foundation models for multivariate healthcare time series. Proceedings of the 4th Machine Learning for Health Symposium. 2025. 259: 668-679.
[52] Woo G, Liu C, Kumar A, et al. Unified training of universal time series forecasting transformers. ICML. 2024: 53140-53164.
[53] Wang X, Zhu R, Xue JH. UC-PUAL: A universally consistent classifier of positive-unlabelled data. Pattern Recognition. 2026. 169: 111892.
[54] Wang X, Zhu R, Xue JH. GKF-PUAL: A group kernel-free approach to positive-unlabeled learning with variable selection. Information Sciences. 2025. 690: 121574.

二、研究内容及方案

1. 研究目标、内容及拟解决的关键问题

1.1 研究目标和内容

本项目面向真实临床中连续、异步且不完整的患者 EHR 数据过程，旨在形成可复用、可迁移的多模态大模型后训练方法体系。借助这一方法体系，现有医疗多模态大模型能够更有效地利用跨时间尺度、跨模态的纵向证据，提升对患者状态及病程演变的整体理解，推动其从同步、静态样本处理拓展到连续临床过程建模，并为疾病进展分析、动态风险评估和临床决策支持提供方法与技术基础。

总体目标围绕三项递进且相互衔接的研究内容展开。第一，提出面向目标时刻跨模态建模的临床时序表征方法，使规则与不规则、多变量和多尺度时序能够在保留数值动态、医学概念语义、真实观测时间和采样状态的条件下接入多模态基座模型，并与影像、文本等模态建立目标时刻关联。第二，在形成可用时序表示的基础上，建立缺失或失效模态在目标时刻的生成式 embedding 补全、可靠性评估及融合机制，利用历史真实观测、当前可用模态和时间信息推断缺失证据，形成涵盖生成结果可靠性、按需使用及真实—生成证据协同融合的基座模型能力。第三，进一步提出异步多模态数据的共同时间组织方法，建立多模态基座模型对先后、间隔、持续和时效关系的时间感知能力及相应评测方法，使模型能够依据真实物理时间关系选择、关联和使用证据。三项研究内容分别解决证据如何表示、如何补全以及如何按时间组织的问题，项目将通过基于 PEFT 的多模态后训练使其协同接入已有基座模型，在充分利用模型原有视觉—语言知识和跨模态能力的基础上，形成可迁移、可验证的异步 EHR 数据建模能力。

1.2 拟解决的关键科学问题

科学问题一：规则与不规则采样、多变量交互及时间尺度如何改变不同临床时序变量所表达的患者状态信息；在不同情况下，如何将这些信息对齐到多模态基座模型中？ 临床时序变量的数值变化与观测过程相互耦合，相同变量及其取值在不同采样模式、变量组合和时间尺度下可能具有不同含义。为此需要明确不同数据形态中应保留哪些数值动态、真实观测时间、变量关系、医学概念语义和采样状态，以及这些信息在何种条件下能够与影像、文本等模态建立目标时刻关联。

科学问题二：目标时刻缺失或失效模态在何种条件下能够由既有证据推断，如何与其他模态数据融合；其可识别性与可靠性由什么决定？ 历史模态表示同时包含仍然有效的信息和随病程变化的信息，当前可用模态、观测状态与时间间隔又共同限定了目标状态的可推断范围。需要明确这些因素如何约束目标模态 embedding 的条件分布，以及生成结果的来源、不确定性、内容—时间一致性和下游效用如何共同影响可靠性控制与融合结果。

科学问题三：多模态基座模型如何理解数据的先后、间隔、持续和时效等时间关系；如何编码不同模态的数据，何种后训练范式能够使模型正确理解数据的时间关系并产生有效的时间感知？ 不同模态编码结果对应不同的时间点、持续区间和采样尺度，输入时间戳或按照时间排序并不意味着模型已经理解这些物理时间关系。需要明确时间信息与模态内容应当如何共同组织，以及不同后训练目标和行为约束如何影响模型的证据选择、跨模态关联和时间推理。

2. 拟采取的研究方案、技术路线及可行性分析

2.1 总体方案与技术路线

本项目以患者时间流和决策时刻 t 为基本研究对象。首先，由模态专用编码器分别获得时序、影像、文本和生理信号的内容 embedding，同时为每个表示保留时点或区间、模态来源、观测状态和采样信息。其次，依据真实时点或区间将各模态 embedding 映射到以决策时刻为参照的共同临床时间坐标，并先以时间距离、方向和区间重叠限定候选交互范围，再由内容相关性学习跨模态聚合。由于不同模态在目标时刻的证据覆盖并不完整，对于覆盖不足的模态—时间区域，生成模块将按需输出带来源和不确定性的候选 embedding。在此基础上，系统根据局部状态变化、证据密度和任务需求进行多分辨率重采样，从而形成数量可控的多模态时间

token。最后，通过分层更新与 PEFT，使基座模型的证据选择和推理对先后、间隔、持续和时效关系产生稳定、可检验的响应，进而建立多模态时间感知能力。



图 2　总体技术路线。研究内容一形成面向目标时刻跨模态建模的临床时序表示；研究内容二建立缺失或失效模态的生成式补全、可靠性评估及融合机制；研究内容三将点观测、连续片段和叙述区间映射到共同临床时间坐标，通过时间约束与内容相关的跨模态聚合及自适应多分辨率重采样形成紧凑的多模态时间表示，并建立时间感知及其评测方法。研究内容二与研究内容三相互约束，基于参数高效微调的多模态后训练贯穿三项研究内容，最终通过行为干预和迁移实验检验所形成能力的可靠性与适用边界。

2.2 各项研究内容的实施方案

研究内容一实施方案。 将现有通用及医疗 TSFM 作为可替换编码器和对照，系统比较三类接入方式：以整段序列 embedding 接入、保留分段或事件级 token

接入，以及围绕目标时刻进行条件化多尺度重采样后接入。在此基础上，按数据形态分别设置比较方案：规则采样数据，比较多尺度分块、时频表示和连续编码；对于不规则数据，比较事件级表示、连续时间表示及其多尺度聚合；对于多变量数据，则进一步比较通道独立编码、显式变量交互和异步通道交互。所有方案均记录观测时间、变量身份、医学概念关系和观测状态，并比较直接使用缺失标记与估计患者—变量—时间依赖观测概率的差异。以患者结局、疾病进展等下游任务及跨任务、跨模态组合的迁移结果作为对齐效果的主要判据，同时通过掩蔽重构、变量关系恢复、观测机制识别、目标时刻跨模态匹配、信息保持和上下文开销分析其作用来源及适用范围。

研究内容二实施方案。 在存在真实目标模态的样本上构造结构化掩蔽，以历史观测、其他可用模态、观测状态和时间间隔为条件，学习目标 embedding 的条件分布。将生成 embedding 与同一患者、同一目标时刻的真实观测 embedding 成对比较，并设置不补全、使用生成表示和使用真实观测表示三种输入条件，比较表示一致性、与其他模态的关联、下游输出和可靠性评估结果。自然缺失样本没有可验证的目标值，这类样本只用于推断，不把未知值作为监督。随后通过系统改变历史观测覆盖、可用模态组合和时间间隔，分析目标表示的可恢复程度及其不确定性变化，从而界定缺失或失效模态的适用条件。在明确适用条件后，进一步比较直接生成完整表示与分别处理相对稳定信息和动态变化信息两类方案。生成模块输出候选 embedding 及不确定性后，还需与历史真实观测、当前其他模态和备选生成结果进行内容与时间一致性检查。按需机制先以时间间隔和校准后不确定性建立可解释基线，再进一步研究基于预期下游效用的触发策略。对于具有正例—未标注结构的下游任务，项目还将引入 PU 风险估计和概率校准，避免把未标注样本直接作为阴性监督；校准后的效用与风险则反馈到补全触发、候选表示选择和融合权重学习，从而在标签监督和表示生成两个层面实施可靠性控制。

研究内容三实施方案。 将各模态编码结果统一表示为“内容 embedding＋时间点或区间＋模态与观测状态”，保留内容与时间之间的对应关系。以决策时刻为原点建立共同临床时间坐标，依据时间距离、方向和区间重叠筛选候选邻域，再由内容相似性和模态组合学习跨模态聚合权重。针对连续时间上的不等间隔变化、离散时间点和持续时间段，分别保留真实时间距离、事件时点、片段长度以及文本叙述中可能存在不确定性的区间边界。在此基础上，多尺度采样查询根据局部变化幅

度、观测密度、跨模态覆盖和不确定性动态决定时间分辨率：平稳且观测密集的区间合并冗余，快速变化、稀疏关键事件和多模态冲突附近保留细粒度。为区分各机制的实际作用，所有消融实验均在等 token 预算下比较向量拼接、按模态串联、固定时间栅格、仅附加时间编码、仅进行时间坐标映射和完整方案。

多模态后训练与迁移验证方案。 为使三项研究内容逐步接入基座模型，项目采用四阶段后训练。第一阶段冻结模态编码器和基座模型主干，利用掩蔽重建、观测机制识别及聚合前后内容一致性，训练投影、时间坐标映射、跨模态聚合和重采样模块。第二阶段在此基础上训练目标时刻生成与可靠性控制，使真实与生成 embedding 采用一致的时间元数据格式，进入同一聚合过程。第三阶段比较冻结、部分更新和采用 PEFT 更新基座模型的方案，通过跨模态时间匹配、证据时段定位、时间一致性判断和临床指令任务，使基座模型具备依据多模态时间 token 中物理时间关系组织证据的能力。第四阶段利用下游监督训练补全触发与证据选择。整个训练过程持续监测各模态损失、跨模态聚合权重、表示敏感性和梯度方向，以识别并控制文本主导、组件更新不平衡、真实—生成证据失衡及目标冲突。

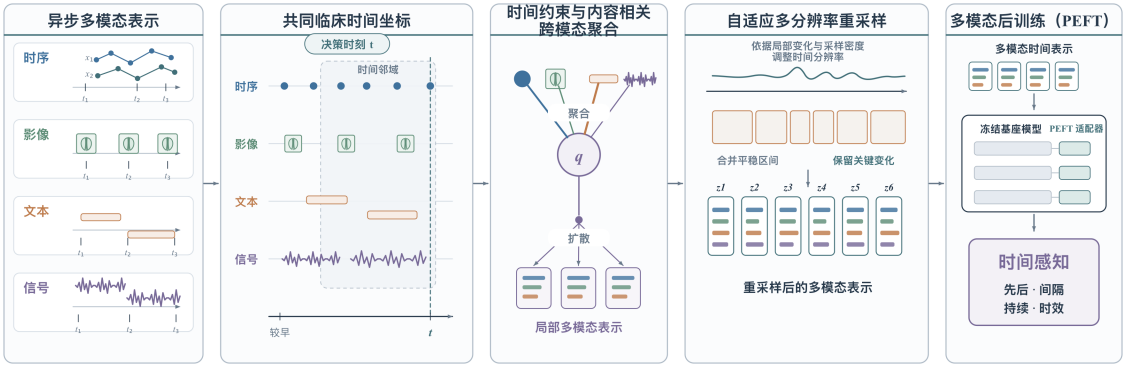


图 3　异步多模态时间感知的形成机制。各模态编码结果首先保留其内容表示及真实时点或区间，并映射到以决策时刻为参照的共同临床时间坐标；模型在时间约束与内容相关性的共同作用下完成跨模态聚合，并根据局部变化和采样密度进行自适应多分辨率重采样，形成数量可控的多模态表示。随后冻结基座模型主干并训练 PEFT 适配器，使基座模型学习依据先后、间隔、持续和时效关系组织多模态证据。

2.3 数据构建、实验设置与评测

项目以公开脱敏临床数据库为主要数据来源，首先纳入结构化电子病历、临床文本和胸部影像，并在主要数据处理和训练流程稳定后，再逐步扩展至心电和高频生理信号 [1-3]。在数据组织上，项目以患者为单位建立事件时间轴，针对每个任务定义目标时刻和预测窗口，记录各模态最近一次真实观测、与目标时刻的间隔、

模态可用状态、采样模式及观测概率上下文。为避免患者层面的信息泄漏，训练、验证和测试集按患者互斥划分；涉及时间外推的实验进一步采用时间顺序切分，防止同一患者不同住院记录或未来观测造成泄漏。

评测将与三项研究内容一一对应。对于时序跨模态对齐，以患者结局、疾病进展等下游任务的收益及跨任务、跨模态组合和基座模型的迁移表现为主要判据，并结合跨模态检索、掩蔽重构、变量关系恢复、采样模式利用、信息保持和 token 开销分析原因。对于生成式补全，在具有真实观测的样本上成对比较生成与观测 embedding 的表示、内容和时间一致性，并比较不补全、使用生成表示和使用真实观测表示时的任务输出、不确定性估计和下游概率校准；自然缺失样本仅评价预测和择用策略，不以无法观测的目标表示衡量生成误差。对于时间感知，构造临床上合理的成对案例，在保持模态内容不变时分别改变关键事件先后、连续时间间隔和持续时间，检验模型答案及所选证据是否相应改变；在保持真实物理时间不变时只改变输入 token 顺序，检验答案是否稳定，并评价时间点和时间段的证据定位。在此基础上，多模态后训练还将评价模态学习平衡、目标梯度一致性、原有视觉—语言能力保持，以及模型在患者结局、疾病进展、临床事件理解和时间证据定位等任务上的迁移表现。结果按时间跨度、采样密度、观测概率、模态子集、疾病、患者亚组、任务和基座模型分层报告，并在适用任务中单独评价正例—未标注条件下的分类与概率校准。为保证比较公平，对照组统一采用等 token 预算，避免把上下文长度、数据规模或参数量差异误认为方法收益。

2.4 可行性分析与风险应对

数据和方法可行。 重症监护医学信息数据库第四版（Medical Information Mart for Intensive Care IV, MIMIC-IV）及其胸部 X 线数据库（MIMIC Chest X-Ray Database, MIMIC-CXR）等公开脱敏资源具有成熟访问流程和标准任务，能够支持项目的核心验证。双方前期成果已覆盖多尺度和不规则时序、观测偏倚、医学概念、潜在跨模态对应、缺失模态融合、目标时刻生成、纵向动态建模和模态学习失衡 [8,9,23,24,38-45]，为三项研究内容提供了直接的方法基础。项目将复用公开模态编码器和已有基座模型，使新增计算主要集中于 embedding 空间中的时间坐标映射、跨模态聚合、重采样、生成和轻量适配，而不需要从头训练基座模型。

团队和资源可行。 双方分别在时序学习、PU learning 与统计分类、临床多模态健康信息学方面形成互补积累，能够从数据表示、可靠学习和多模态建模等不

同角度共同推进项目。现有公共计算环境能够支持模态编码器训练、embedding 离线缓存、生成模块实验和中等规模开源基座模型 PEFT 等核心验证。考虑到大规模多模态实验可能带来较高计算开销，项目将按“小模型和短时间窗验证机制—中等规模基座模型验证迁移—必要时扩展模态和规模”的顺序推进，从而避免核心科学假设依赖一次性大规模端到端训练。

主要风险及应对。（1）表示过细可能超出 token 和显存预算，过度重采样又可能损失短时异常。对此，项目将采样粒度和 token 预算作为显式变量，根据信息恢复、关键事件保留、下游效用和计算成本联合选择。（2）时间约束下的跨模态聚合可能退化为邻近时间内的机械平均，或者被高频模态主导。项目采用“时间关系限定候选邻域＋内容相关聚合”，并设置时间接近但内容不对应的反事实样本和模态消融。（3）生成表示可能产生偏差或被过度采信。项目保持真实观测通路独立，结合来源标记、不确定性估计、内容—时间一致性和下游概率校准实施可靠性控制。（4）基座模型可能忽略多模态 embedding 中的物理时间关系。项目将通过针对性后训练、时间坐标映射与跨模态聚合消融，以及受控时间扰动和行为化时间任务直接检验。（5）后训练可能出现文本主导、组件更新不平衡和原有能力遗忘。项目采用分阶段优化、参数和梯度通路隔离、模态级消融及后训练前后能力对照。（6）多模态长时间窗、多候选生成和密集对照实验可能产生阶段性的算力与存储峰值，因而公共计算资源未必能够同时满足全部实验需求。项目将采用冻结编码器、离线 embedding 缓存、稀疏时间邻域、分层重采样、混合精度和基于 PEFT 的后训练降低计算开销，并根据实验负载统筹任务排期；必要时，在经费预算和管理规定允许的范围内，使用项目经费补充专用计算与存储资源或租用合规算力服务，同时报告准确性—token 数量—显存—训练时间之间的权衡。（7）全模态样本可能不足。项目采用结构化缺失增强和按模态可用性分层评测，避免把完整模态子集作为唯一结论来源。

项目将以公开数据完成主要研究，核心结论不依赖尚未确定的临床合作。如执行期间具备合适的临床合作条件，可在完成数据授权和伦理审批后，进一步探索专家评价或独立外部验证。

3. 本项目的创新之处

（1）提出面向决策时刻、兼顾观测过程的临床时序跨模态对齐方法。 将数值动态、医学概念语义和患者—变量—时间依赖的观测过程共同纳入时序表示，以目标时刻为参照建立时序与影像、文本之间的内容及时间对应。对齐效果以多项临床下游任务的收益及跨任务、跨模态组合的迁移性为主要判据，并通过目标时刻匹配和等 token 预算下的消融分析判断收益是否来自对齐机制。

（2）建立面向多模态大模型的目标时刻生成式 embedding 补全、对齐与可靠性控制机制。 项目区分未采集、完全缺失和时间间隔导致的证据失效，在保留真实观测独立通路的条件下生成候选表示。对于具有真实观测的样本，成对比较生成表示与观测表示的跨模态一致性及其接入基座模型后的任务输出，分析生成误差如何随时间间隔和证据条件变化；再依据来源、不确定性、内容—时间一致性及校准后的下游效用，决定是否使用及如何融合生成表示。

（3）建立覆盖连续时间、时间点和时间段的多模态大模型时间感知机制。 项目保留异步多模态证据的真实时间距离、事件时点与持续区间，通过共同时间坐标映射、跨模态聚合、自适应重采样和多模态后训练，使模型依据物理时间关系选择证据。验证时分别改变关键事件先后、连续时间间隔和持续时间，检查模型答案与证据定位是否正确变化；仅改变输入顺序而保持物理时间不变时，检查答案是否稳定。